

Modelo de Reconocimiento Automático de Señales de Tránsito Vehicular mediante Aprendizaje Profundo de Redes Neuronales Convolucionales

Josué Gastón Távara Idrogo jtavara@unitru.edu.pe

Universidad Nacional de Trujillo Facultad de Ciencias Físicas y Matemáticas Escuela Académico Profesional de Informática

Defensa de tesis 15/12/2018



Resumen

Esta investigación pretende contribuir en la industria automotriz, específicamente en los campos de construcción de vehículos autónomos y de los sistemas avanzados de asistencia al conductor, iniciando con la adquisición de imágenes, luego para el pre-procesamiento, se implementará algoritmos de realce de contraste, reducción de ruido, rotación y proyecciones de escalamiento con la finalidad de aumentar el conjunto de datos y poder ejecutar el aprendizaje profundo a través de arquitecturas de redes neuronales convolucionales. Se realizaron diferentes diseños de arquitecturas convolucionales y se escogió el que obtuvo los mejores indicadores/resultados.

Palabras claves: aprendizaje profundo, redes neuronales convolucionales, procesamiento de imágenes.



Modelo De Reconocimiento Automático De Señales De Tránsito Vehicular Mediante Aprendizaje Profundo De Redes Neuronales Convolucionales

- 1 Introducción
- 2 Motivación
- 3 Formulación del problema
- 4 Importancia de la investigación
- 5 Contribución de la investigación
- 6 Marco teórico
 - Aprendizaje Profundo
 - Red Convolucional
 - Arquitectura del Modelo
 - Componentes del Modelo
- 7 Propuesta o tema central de la tesis
- 8 Resultados de la tesis
- 9 Consideraciones finales
- 10 Referencias bibliograficas



Introducción

- Al conducir en carreteras congestionadas, a veces es difícil mantener los ojos en todas partes a la vez, comprobando el camino por delante, el tráfico venidero, lo que está detrás de usted, tratar de mantener la velocidad permitida; es por ello, que existen mecanismos destinados a reglamentar el tránsito, advertir o informar a los usuarios mediante palabras, sonidos o símbolos determinados.



Introducción

- Al conducir en carreteras congestionadas, a veces es difícil mantener los ojos en todas partes a la vez, comprobando el camino por delante, el tráfico venidero, lo que está detrás de usted, tratar de mantener la velocidad permitida; es por ello, que existen mecanismos destinados a reglamentar el tránsito, advertir o informar a los usuarios mediante palabras, sonidos o símbolos determinados.
- La policía de tránsito o las **señalizaciones vehiculares** que según sea el caso, en todos los países regulan el tránsito e informan al usuario sobre direcciones, rutas, destinos, así como dificultades existentes en las carreteras y previenen cualquier peligro que podría presentarse en la circulación vehicular.



Introducción

- La inseguridad vial es un problema de interés mundial, según el último informe de la OMS (Organización Mundial de la salud) anualmente cerca de 1,3 millones de personas mueren alrededor del mundo y entre 20 y 50 millones padecen traumatismos no mortales,(OMS, 2017). Son distintas las causas que conllevan a este problema, de las cuales las principales pueden ser la falta de concientización y educación vial.



Introducción

- El Perú y la capital Lima se encuentran respectivamente en la lista de peores países y ciudades para conducir en America Latina, según el Índice Global de Satisfacción del Conductor (Waze, 2016), lo cual se ve reflejado en que los últimos años se ha incrementado el índice de mortandad originados por los accidentes de tránsito siendo las principales causas de los mismos el exceso de velocidad, estado de ebriedad del conductor y sobretodo el desacato a las señales de tránsito, todas ellas de responsabilidad directa del conductor del vehículo motorizado,(SUTRAN, 2014).



Introducción

- El Perú y la capital Lima se encuentran respectivamente en la lista de peores países y ciudades para conducir en America Latina, según el Índice Global de Satisfacción del Conductor (Waze, 2016), lo cual se ve reflejado en que los últimos años se ha incrementado el índice de mortandad originados por los accidentes de tránsito siendo las principales causas de los mismos el exceso de velocidad, estado de ebriedad del conductor y sobretodo el desacato a las señales de tránsito, todas ellas de responsabilidad directa del conductor del vehículo motorizado, (SUTRAN, 2014).
- Es por ello que trabajar en obtener vehículos más seguros es un factor fundamental para prevenir de alguna forma los accidentes de tránsito o reducir la probabilidad de que estos sean producidos, (OMS, 2017).



Modelo De Reconocimiento Automático De Señales De Tránsito Vehicular Mediante Aprendizaje Profundo De Redes Neuronales Convolucionales

- 1 Introducción
- 2 Motivación**
- 3 Formulación del problema
- 4 Importancia de la investigación
- 5 Contribución de la investigación
- 6 Marco teórico
 - Aprendizaje Profundo
 - Red Convolucional
 - Arquitectura del Modelo
 - Componentes del Modelo
- 7 Propuesta o tema central de la tesis
- 8 Resultados de la tesis
- 9 Consideraciones finales
- 10 Referencias bibliograficas



Motivación

- Para contribuir con lo antes mencionado, se han venido planteando formas que permitan la asistencia en el reconocimiento de señales de tránsito, la cual es un problema de clasificación multicategórica que comúnmente presenta desigualdades en las frecuencias de aparición de las categorías. Además, las señales de tránsito muestran una amplia gama de variaciones entre las clases en términos de color, forma, subconjuntos de clases que son muy similares entre sí y la presencia de símbolos, leyendas o texto. A esto es sumado, las grandes variaciones en las apariencias visuales debido a cambios de iluminación, oclusiones parciales, rotaciones, condiciones meteorológicas, escalamiento, etc.



Motivación

- Para contribuir con lo antes mencionado, se han venido planteando formas que permitan la asistencia en el reconocimiento de señales de tránsito, la cual es un problema de clasificación multicategórica que comúnmente presenta desigualdades en las frecuencias de aparición de las categorías. Además, las señales de tránsito muestran una amplia gama de variaciones entre las clases en términos de color, forma, subconjuntos de clases que son muy similares entre sí y la presencia de símbolos, leyendas o texto. A esto es sumado, las grandes variaciones en las apariencias visuales debido a cambios de iluminación, oclusiones parciales, rotaciones, condiciones meteorológicas, escalamiento, etc.
- Todo esto representa un reto para el reconocedor/clasificador de señales de tránsito vehicular y es por ello que se han venido realizando diversas investigaciones, donde esta forma parte de una de ellas.



Modelo De Reconocimiento Automático De Señales De Tránsito Vehicular Mediante Aprendizaje Profundo De Redes Neuronales Convolucionales

- 1 Introducción
- 2 Motivación
- 3 Formulación del problema**
- 4 Importancia de la investigación
- 5 Contribución de la investigación
- 6 Marco teórico
 - Aprendizaje Profundo
 - Red Convolucional
 - Arquitectura del Modelo
 - Componentes del Modelo
- 7 Propuesta o tema central de la tesis
- 8 Resultados de la tesis
- 9 Consideraciones finales
- 10 Referencias bibliograficas



Formulación del problema

En este trabajo, se propone discutir el modelo de redes neuronales convolucionales basado en el problema del reconocimiento de imágenes para responder a la siguiente pregunta:

¿Cómo se puede reconocer de manera automática señales de tránsito vehicular?



Modelo De Reconocimiento Automático De Señales De Tránsito Vehicular Mediante Aprendizaje Profundo De Redes Neuronales Convolucionales

- 1 Introducción
- 2 Motivación
- 3 Formulación del problema
- 4 Importancia de la investigación**
- 5 Contribución de la investigación
- 6 Marco teórico
 - Aprendizaje Profundo
 - Red Convolucional
 - Arquitectura del Modelo
 - Componentes del Modelo
- 7 Propuesta o tema central de la tesis
- 8 Resultados de la tesis
- 9 Consideraciones finales
- 10 Referencias bibliograficas



Importancia de la investigación - Justificación Académica

- La importancia de esta investigación en el punto de vista de ciencias de la computación se justifica en poner en práctica los conocimientos adquiridos en la formación académica, siendo los más resaltables el tema de procesamiento de imágenes, cálculo matemático e inteligencia artificial con la finalidad de obtener un modelo robusto de redes neuronales convolucionales basadas en el aprendizaje profundo (deep learning) que permita analizar el contenido de imágenes para el reconocer de señales de tránsito vehicular.



Importancia de la investigación - Justificación Académica

- La importancia de esta investigación en el punto de vista de ciencias de la computación se justifica en poner en práctica los conocimientos adquiridos en la formación académica, siendo los más resaltables el tema de procesamiento de imágenes, cálculo matemático e inteligencia artificial con la finalidad de obtener un modelo robusto de redes neuronales convolucionales basadas en el aprendizaje profundo (deep learning) que permita analizar el contenido de imágenes para el reconocer de señales de tránsito vehicular.
- En este sentido, esta investigación pretende la elaboración de un modelo basado en el aprendizaje profundo de redes convolucionales que permita el reconocimiento de señales de tránsito vehicular. La siguiente figura muestra un diagrama de bloques con la secuencia de actividades que demanda el reconocimiento.



Importancia de la investigación - Justificación Social

- Teniendo conocimiento de lo descrito en la realidad problemática, la visibilidad y conocimiento de señales de tráfico es crucial para la seguridad de los conductores y es por ello que la introducción de un modelo de reconocimiento de señales de tránsito que funcione en diferentes contextos puede formar parte de la solución a que constantes infracciones y muertes se puedan evitar y en consecuencia reducir estos índices progresivamente.



Importancia de la investigación - Justificación Social

- Teniendo conocimiento de lo descrito en la realidad problemática, la visibilidad y conocimiento de señales de tráfico es crucial para la seguridad de los conductores y es por ello que la introducción de un modelo de reconocimiento de señales de tránsito que funcione en diferentes contextos puede formar parte de la solución a que constantes infracciones y muertes se puedan evitar y en consecuencia reducir estos índices progresivamente.
- A continuación algunos ejemplos:



Importancia de la investigación - Justificación Social

- Teniendo conocimiento de lo descrito en la realidad problemática, la visibilidad y conocimiento de señales de tráfico es crucial para la seguridad de los conductores y es por ello que la introducción de un modelo de reconocimiento de señales de tránsito que funcione en diferentes contextos puede formar parte de la solución a que constantes infracciones y muertes se puedan evitar y en consecuencia reducir estos índices progresivamente.
- A continuación algunos ejemplos:
 - Dar una notificación al no darse cuenta de un cambio en el límite de velocidad



Importancia de la investigación - Justificación Social

- Teniendo conocimiento de lo descrito en la realidad problemática, la visibilidad y conocimiento de señales de tráfico es crucial para la seguridad de los conductores y es por ello que la introducción de un modelo de reconocimiento de señales de tránsito que funcione en diferentes contextos puede formar parte de la solución a que constantes infracciones y muertes se puedan evitar y en consecuencia reducir estos índices progresivamente.
- A continuación algunos ejemplos:
 - Dar una notificación al no darse cuenta de un cambio en el límite de velocidad
 - El aviso de que se está cometiendo una infracción al girar o estacionarse donde no se debe



Importancia de la investigación - Justificación Social



Importancia de la investigación - Justificación Social

- — La advertencia de un peligro potencial por delante.



Importancia de la investigación - Justificación Social

- - La advertencia de un peligro potencial por delante.
 - Una aplicación móvil que dé la posibilidad de reconocer automáticamente aquella señal de tránsito que usuarios puedan desconocer serviría como aporte en la educación vial.



Importancia de la investigación - Justificación Social

- - La advertencia de un peligro potencial por delante.
 - Una aplicación móvil que dé la posibilidad de reconocer automáticamente aquella señal de tránsito que usuarios puedan desconocer serviría como aporte en la educación vial.
 - Podría ser un componente útil en cámaras de video vigilancia convirtiendolas en más inteligentes con la capacidad de monitorear que las señales de tránsito sean respetadas.



Importancia de la investigación - Justificación Social

- - La advertencia de un peligro potencial por delante.
 - Una aplicación móvil que dé la posibilidad de reconocer automáticamente aquella señal de tránsito que usuarios puedan desconocer serviría como aporte en la educación vial.
 - Podría ser un componente útil en cámaras de video vigilancia convirtiendolas en más inteligentes con la capacidad de monitorear que las señales de tránsito sean respetadas.
- En este sentido, esta investigación pretende la elaboración de un modelo basado en el aprendizaje profundo de redes convolucionales que permita el reconocimiento de señales de tránsito vehicular. La siguiente figura muestra un diagrama de bloques con la secuencia de actividades que demanda el reconocimiento.



Modelo De Reconocimiento Automático De Señales De Tránsito Vehicular Mediante Aprendizaje Profundo De Redes Neuronales Convolucionales

- 1 Introducción
- 2 Motivación
- 3 Formulación del problema
- 4 Importancia de la investigación
- 5 Contribución de la investigación**
- 6 Marco teórico
 - Aprendizaje Profundo
 - Red Convolucional
 - Arquitectura del Modelo
 - Componentes del Modelo
- 7 Propuesta o tema central de la tesis
- 8 Resultados de la tesis
- 9 Consideraciones finales
- 10 Referencias bibliograficas



Contribución de la investigación

- Todos los hechos descritos hacen que el reconocimiento de las señales de tránsito sea un reto desafiante y esencial en muchos aspectos, no solo para contribuir en los esfuerzos de la industria automotriz en el campo de la asistencia al conductor, sino también para organismos internacionales y gubernamentales quienes se dan cuenta de la problemática que representa la inseguridad vial y buscan constantemente introducir nuevos mecanismos y tecnologías que faciliten y mejoren la conducción vehicular para el beneficio propio del conductor y en general para la seguridad vial de la sociedad.



Modelo De Reconocimiento Automático De Señales De Tránsito Vehicular Mediante Aprendizaje Profundo De Redes Neuronales Convolucionales

- 1 Introducción
- 2 Motivación
- 3 Formulación del problema
- 4 Importancia de la investigación
- 5 Contribución de la investigación
- 6 Marco teórico**
 - Aprendizaje Profundo
 - Red Convolucional
 - Arquitectura del Modelo
 - Componentes del Modelo
- 7 Propuesta o tema central de la tesis
- 8 Resultados de la tesis
- 9 Consideraciones finales
- 10 Referencias bibliograficas



Aprendizaje Profundo

- **Aprendizaje Profundo**



Aprendizaje Profundo

- **Aprendizaje Profundo**

- ▶ El verdadero desafío para la inteligencia artificial fue y es resolver las tareas que son fáciles de realizar para las personas pero difíciles de describir de manera formal, problemas que resolvemos intuitivamente, que se sienten automáticos, como reconocer palabras, rostros u objetos en las imágenes (Goodfellow et al., 2016).



● Aprendizaje Profundo

- ▶ El verdadero desafío para la inteligencia artificial fue y es resolver las tareas que son fáciles de realizar para las personas pero difíciles de describir de manera formal, problemas que resolvemos intuitivamente, que se sienten automáticos, como reconocer palabras, rostros u objetos en las imágenes (Goodfellow et al., 2016).
- ▶ El aprendizaje automático es considerada como la mejor técnica de la inteligencia artificial (IA); es decir, es el campo de la IA que hoy en día muestra la mayor promesa al proporcionar herramientas que la industria y la sociedad pueden usar para producir algún cambio.



Aprendizaje Profundo

● Aprendizaje Profundo

- ▶ El verdadero desafío para la inteligencia artificial fue y es resolver las tareas que son fáciles de realizar para las personas pero difíciles de describir de manera formal, problemas que resolvemos intuitivamente, que se sienten automáticos, como reconocer palabras, rostros u objetos en las imágenes (Goodfellow et al., 2016).
- ▶ El aprendizaje automático es considerada como la mejor técnica de la inteligencia artificial (IA); es decir, es el campo de la IA que hoy en día muestra la mayor promesa al proporcionar herramientas que la industria y la sociedad pueden usar para producir algún cambio.
- ▶ En tal sentido, el aprendizaje automático toma algunas de las ideas centrales de la inteligencia artificial y las enfoca en resolver problemas del mundo real con redes neuronales diseñadas para imitar nuestra propia toma de decisiones.



Aprendizaje Profundo

- Por otro lado, el aprendizaje profundo o avanzado de máquinas (del inglés, **deep learning**) se centra aún más estrechamente en un subconjunto de herramientas y técnicas del aprendizaje automático y los aplica a la solución de casi cualquier problema que requiera "pensamiento", ya sea humano o artificial.



Aprendizaje Profundo

- Por otro lado, el aprendizaje profundo o avanzado de máquinas (del inglés, **deep learning**) se centra aún más estrechamente en un subconjunto de herramientas y técnicas del aprendizaje automático y los aplica a la solución de casi cualquier problema que requiera "pensamiento", ya sea humano o artificial.
- Se puede sostener que el aprendizaje automático es el único enfoque viable para construir sistemas de inteligencia artificial que puedan operar en entornos complicados del mundo real y el **aprendizaje profundo** es, a su vez, un tipo particular de aprendizaje automático que logra gran poder y flexibilidad al representar el mundo como una jerarquía de conceptos anidados, con cada concepto definido en relación con conceptos más simples y representaciones más abstractas calculadas en base a representaciones menos abstractas.



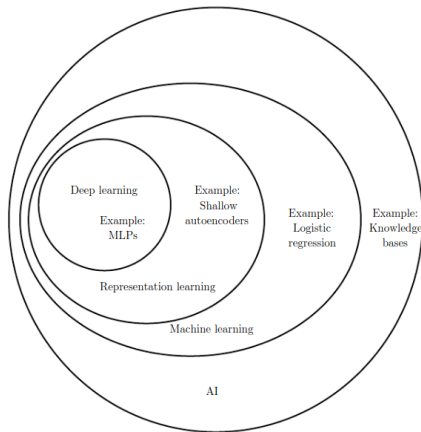


Figura: Diagrama de Venn donde cada sección incluye un ejemplo de una tecnología de IA (ilustra la relación entre estas diferentes disciplinas de la IA)

Fuente: (Goodfellow et al., 2016)



Aprendizaje Profundo

- El aprendizaje profundo es un enfoque específico utilizado para construir y entrenar redes neuronales para la toma de decisiones altamente prometedoras, (Goodfellow et al., 2016).



Aprendizaje Profundo

- El aprendizaje profundo es un enfoque específico utilizado para construir y entrenar redes neuronales para la toma de decisiones altamente prometedoras, (Goodfellow et al., 2016).
- Se considera que un algoritmo es profundo si los datos de entrada se pasan a través de una serie de no linealidades o transformaciones no lineales antes de que se emita.



Aprendizaje Profundo

- El aprendizaje profundo es un enfoque específico utilizado para construir y entrenar redes neuronales para la toma de decisiones altamente prometedoras, (Goodfellow et al., 2016).
- Se considera que un algoritmo es profundo si los datos de entrada se pasan a través de una serie de no linealidades o transformaciones no lineales antes de que se emita.
- Este enfoque permitir que las computadoras aprendan de la experiencia y entiendan el mundo en términos de una jerarquía de conceptos, con cada concepto definido a través de su relación con conceptos más simples.



Aprendizaje Profundo

- El aprendizaje profundo es un enfoque específico utilizado para construir y entrenar redes neuronales para la toma de decisiones altamente prometedoras, (Goodfellow et al., 2016).
- Se considera que un algoritmo es profundo si los datos de entrada se pasan a través de una serie de no linealidades o transformaciones no lineales antes de que se emita.
- Este enfoque permitir que las computadoras aprendan de la experiencia y entiendan el mundo en términos de una jerarquía de conceptos, con cada concepto definido a través de su relación con conceptos más simples.
- Al reunir el conocimiento de la experiencia, este enfoque evita la necesidad de que los operadores humanos especifiquen formalmente todo el conocimiento que necesita la computadora.



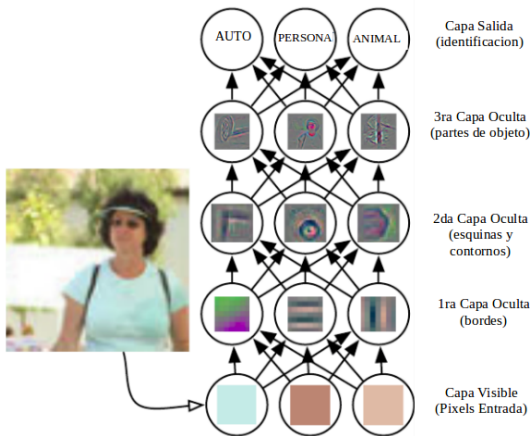


Figura: El aprendizaje profundo permite a la computadora construir conceptos complejos a partir de conceptos más simples

Fuente propia



Red Convolucional

- Nueve de cada diez veces, cuando se escucha que el aprendizaje profundo rompe una nueva barrera tecnológica, las redes neuronales convolucionales están involucradas. También llamados CNN(del inglés , **Convolutional Neural Networks**) o **ConvNets**, estas son las preferidas del campo de redes neuronales profundas. Han aprendido a clasificar las imágenes en categorías incluso mejor que los humanos en algunos casos, (Rohrer, 2016).



Red Convolucional

- Nueve de cada diez veces, cuando se escucha que el aprendizaje profundo rompe una nueva barrera tecnológica, las redes neuronales convolucionales están involucradas. También llamados CNN(del inglés , **Convolutional Neural Networks**) o **ConvNets**, estas son las preferidas del campo de redes neuronales profundas. Han aprendido a clasificar las imágenes en categorías incluso mejor que los humanos en algunos casos, (Rohrer, 2016).
- Estas son muy similares a las redes neuronales ordinarias, están formadas por neuronas que tienen pesos y biases(sesgos) que se pueden aprender durante el entrenamiento de estas. Cada neurona recibe algunas entradas y realiza operaciones matemáticas.



Red Convolutiva

- Una ConvNet se caracteriza por tener una secuencia de capas donde cada una de estas transforma un volumen de activaciones en otro nuevo a través de funciones y el aprendizaje profundo se produce cuando se utilizan varias de estas capas variando los parámetros de configuración dentro y entre dichas capas.



Red Convolutacional

- Una ConvNet se caracteriza por tener una secuencia de capas donde cada una de estas transforma un volumen de activaciones en otro nuevo a través de funciones y el aprendizaje profundo se produce cuando se utilizan varias de estas capas variando los parámetros de configuración dentro y entre dichas capas.
- El resultado de las CNNs es que pueden encontrar si una característica está en una imagen sin preocuparse exactamente de donde está. Esto ayuda a resolver el problema de las computadoras al comparar imágenes de manera hiper-literal, es decir, que coincida pixel a pixel para que se trate de imágenes iguales.



Red Convolucional




Figura: Analisis de una CNN

Fuente: (Rohrer, 2016)



Red Convolucional

- **Red Convolucional - Terminologías**



Red Convolutacional

- **Red Convolutacional - Terminologías**

- ▶ Una es cuando la red convolutacional es vista como un número largo de capas simples y cada paso del procesamiento se considera como una capa en sí misma.



Red Convolutacional

● Red Convolutacional - Terminologías

- ▶ Una es cuando la red convolutacional es vista como un número largo de capas simples y cada paso del procesamiento se considera como una capa en sí misma.
- ▶ Otra terminología es cuando la red convolutacional es vista como un número pequeño de capas relativamente complejas, donde cada capa tiene múltiples etapas.



● Red Convolutacional - Terminologías

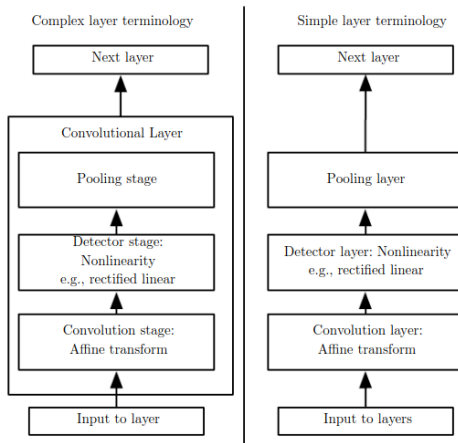


Figura: Terminología de capas complejas(izquierda) y de capas simples(derecha)

Fuente: (Goodfellow et al., 2016)



Arquitectura del Modelo

- La arquitectura de la red está inspirada en el arquitectura Inception (Szegedy et al., 2014) y en la arquitectura AlexNet(Krizhevsky et al., 2012) para la clasificación de imágenes. En la arquitectura Inception, el modelo creado es denominado GoogLeNet, similar a AlexNet donde varios módulos iniciales son apilados uno sobre el otro para producir el resultado final. En el módulo de inicio, en ese tipo de red se usaron diversos tamaños de filtros convolucionales para capturar características de diferente abstracción.



Arquitectura del Modelo

- La arquitectura de la red está inspirada en el arquitectura Inception (Szegedy et al., 2014) y en la arquitectura AlexNet(Krizhevsky et al., 2012) para la clasificación de imágenes. En la arquitectura Inception, el modelo creado es denominado GoogLeNet, similar a AlexNet donde varios módulos iniciales son apilados uno sobre el otro para producir el resultado final. En el módulo de inicio, en ese tipo de red se usaron diversos tamaños de filtros convolucionales para capturar características de diferente abstracción.
- El alto nivel de abstracción se captura con filtros de mayor tamaño y el de un nivel inferior con filtros de menor tamaño. Procesando información visual a diferentes escalas y al concatenarlas se obtiene un nivel eficiente de abstracción.



Arquitectura del Modelo

- En esta investigación se utilizó una versión modificada de las arquitecturas antes mencionadas. Se incorporó **funciones de escala-múltiple** (Sermanet and LeCun, 2011), lo que significa que la salida de las capas convolucionales no solo se envía a la capa posterior, sino que también se ramifica y se introduce al clasificador (capa totalmente conectada). La razón detrás de esto es que cuando el clasificador está tomando una decisión basada en convoluciones, podría encontrar que la salida de la primera o segunda capa convolucional también es útil. Básicamente con las características de escala múltiple depende del clasificador qué nivel de abstracción usar, ya que tiene acceso a las salidas de todas las capas convolucionales, es decir, características en todos los niveles de abstracción.



Arquitectura del Modelo




Figura: Modelo del diseño de la Red propuesta

Fuente propia



Componentes del Modelo

- Capa Convolucional



Componentes del Modelo

- Capa Convolucional
- Capa de Activación ReLU(Rectified Linear Units)



Componentes del Modelo

- Capa Convolutacional
- Capa de Activación ReLU(Rectified Linear Units)
- Capa de Agrupación(Pooling)



Componentes del Modelo

- Capa Convolutacional
- Capa de Activación ReLU(Rectified Linear Units)
- Capa de Agrupación(Pooling)
- Capa totalmente conectada (Fully-connected layer)



Capa Convolutiva

- Los parámetros de la capa convolutiva consisten básicamente en dos datos. La entrada y todo lo que respecta a un conjunto de filtros(también denominados kernels) cuyos valores se aprenden, es decir, empiezan con datos aleatorios y conforme avanza el entrenamiento se van alterando.



Capa Convolutiva

- Los parámetros de la capa convolutiva consisten básicamente en dos datos. La entrada y todo lo que respecta a un conjunto de filtros (también denominados kernels) cuyos valores se aprenden, es decir, empiezan con datos aleatorios y conforme avanza el entrenamiento se van alterando.
- Durante el proceso hacia adelante, se desliza (más precisamente, convolve) cada filtro a través del ancho y alto del volumen de entrada para calcular los productos de puntos entre las entradas del filtro y la entrada en cualquier posición.



Capa Convolutiva




Figura: Posicionamiento del kernel/filtro por pixel

Fuente: Fuente Propia



Capa Convolutiva

- A medida que deslizamos el filtro sobre el ancho y la altura del volumen de entrada produciremos un mapa de activación bidimensional que proporciona las respuestas de ese filtro en cada posición espacial. Por lo que simplemente se multiplica cada píxel en el filtro por el valor del píxel en la imagen. Para luego, sumar las respuestas y dividir las por el número total de píxeles en el filtro.




Figura: Cálculo Convolutiva

Fuente: Fuente Propia



Capa Convolutiva



Capa Convolutiva

- Intuitivamente, la red aprenderá los filtros que se activan cuando ven algún tipo de característica visual, como un borde o contorno en alguna orientación específica. Debido a que la convolución aprovecha tres ideas importantes que pueden ayudar a mejorar un sistema de aprendizaje automático:



Capa Convolutiva

- Intuitivamente, la red aprenderá los filtros que se activan cuando ven algún tipo de característica visual, como un borde o contorno en alguna orientación específica. Debido a que la convolución aprovecha tres ideas importantes que pueden ayudar a mejorar un sistema de aprendizaje automático:
 - ▶ Interacciones dispersas



Capa Convolutiva

- Intuitivamente, la red aprenderá los filtros que se activan cuando ven algún tipo de característica visual, como un borde o contorno en alguna orientación específica. Debido a que la convolución aprovecha tres ideas importantes que pueden ayudar a mejorar un sistema de aprendizaje automático:
 - ▶ Interacciones dispersas
 - ▶ Uso compartido de parámetros



Capa Convolutiva

- Intuitivamente, la red aprenderá los filtros que se activan cuando ven algún tipo de característica visual, como un borde o contorno en alguna orientación específica. Debido a que la convolución aprovecha tres ideas importantes que pueden ayudar a mejorar un sistema de aprendizaje automático:
 - ▶ Interacciones dispersas
 - ▶ Uso compartido de parámetros
 - ▶ Representaciones equivalentes



- Capa Convolutiva - Interacciones dispersas




Figura: Conectividad dispersa vs No dispersa
Fuente:(Rohrer, 2016)

Cuando \mathbf{s} está formado por convolución con un kernel de ancho 3, solo tres salidas se ven afectadas por \mathbf{x} . (Abajo) Cuando \mathbf{s} está formado por la multiplicación de la matriz, la conectividad ya no es dispersa, por lo que todos los resultados se ven afectados por x_3 .



Capa Convolutiva

- **Capa Convolutiva - Interacciones dispersas**



Capa Convolutiva

- **Capa Convolutiva - Interacciones dispersas**

- ▶ Esto significa que necesitamos almacenar menos parámetros, lo que reduce los requisitos de memoria del modelo y mejora su eficiencia estadística. También significa que el cálculo de la salida requiere menos operaciones, (Goodfellow et al., 2016).



Capa Convolutiva

- **Capa Convolutiva - Uso compartido de parámetros**



Capa Convolutiva

- **Capa Convolutiva - Uso compartido de parámetros**

- ▶ En una red neuronal convolutiva, cada miembro del kernel se utiliza en cada posición de la entrada (excepto tal vez algunos de los píxeles de los bordes, dependiendo de las decisiones de diseño con respecto al límite). El uso compartido de parámetros utilizado por la operación de convolución significa que en lugar de aprender conjuntos de parámetros para cada ubicación por separado, aprendemos un solo conjunto por kernel, (Goodfellow et al., 2016).



Capa Convolutiva

- **Capa Convolutiva - Representaciones equivalentes**



Capa Convolutiva

- **Capa Convolutiva - Representaciones equivalentes**

- ▶ La forma particular de compartir los parámetros hace que la capa tenga una propiedad llamada **representaciones equivalentes**. Decir que una función es equivalente significa que si la entrada cambia, la salida cambia de la misma manera.



Capa Convolutiva

- **Capa Convolutiva - Representaciones equivalentes**

- ▶ La forma particular de compartir los parámetros hace que la capa tenga una propiedad llamada **representaciones equivalentes**. Decir que una función es equivalente significa que si la entrada cambia, la salida cambia de la misma manera.
- ▶ La convolución crea un mapa en 2-D de donde aparecen ciertas características en la entrada. Si movemos el objeto en la entrada, su representación se moverá la misma cantidad en la salida.



Capa Convolutiva

- Capa Convolutiva - Representaciones equivalentes




Figura: Resultado de Convolución(conjunto de mapas de activación. generado a partir de 3 filtros para 3 carecteristicas: diagonal derecha, cruzamiento central y diagonal izquierda). Simbolo de convolución: \otimes

Fuente: (Rohrer, 2016)



Capa Convolutiva

● Capa Convolutiva - Construcción de un filtro o kernel

- 1 La extensión espacial es el tamaño del filtro, comúnmente es de tamaño impar tanto en largo y ancho.
- 2 El stride es otra pieza del bloque de construcción básico de los filtros convolucionales. Este representa el 'paso' en la operación de convolución indicando cuánto es que se debe desplazar un filtro en una imagen con cada paso. El filtro se desliza sobre la imagen, se detiene en cada longitud de salto y realiza las operaciones necesarias en ese paso.




Figura: Imagen con stride igual a 2, para el filtro tanto en largura como anchura

Fuente propia



Capa Convolutiva

- **Capa Convolutiva - Construcción de un filtro o kernel**
 - 3 Zero-padding agrega ceros alrededor del borde de una imagen.




Figura: Ejemplo de zero-padding con tamaño 2

Fuente propia



Capa Convolutiva

- **Capa Convolutiva - Ecuación de Convolución**



Capa Convolutiva

- **Capa Convolutiva - Ecuación de Convolución**

- $$conv_j^n = \sum_{k=1}^k x_k^n \times w_{kj}^n + b_n$$

En el que:

- ▶ x son valores de entrada
- ▶ w, b pesos y biases(sesgos) del kernel, respectivamente
- ▶ n es el número de la capa
- ▶ j es el número del filtro de salida
- ▶ k es la cantidad de filtros en la capa $n - 1$ o n



Modelo De Reconocimiento Automático De Señales De Tránsito Vehicular Mediante Aprendizaje Profundo De Redes Neuronales Convolucionales

- 1 Introducción
- 2 Motivación
- 3 Formulación del problema
- 4 Importancia de la investigación
- 5 Contribución de la investigación
- 6 Marco teórico
 - Aprendizaje Profundo
 - Red Convolucional
 - Arquitectura del Modelo
 - Componentes del Modelo
- 7 Propuesta o tema central de la tesis**
- 8 Resultados de la tesis
- 9 Consideraciones finales
- 10 Referencias bibliograficas



Propuesta o tema central de la tesis



Propuesta o tema central de la tesis



Propuesta o tema central de la tesis



Propuesta o tema central de la tesis



Propuesta o tema central de la tesis



Modelo De Reconocimiento Automático De Señales De Tránsito Vehicular Mediante Aprendizaje Profundo De Redes Neuronales Convolucionales

- 1 Introducción
- 2 Motivación
- 3 Formulación del problema
- 4 Importancia de la investigación
- 5 Contribución de la investigación
- 6 Marco teórico
 - Aprendizaje Profundo
 - Red Convolucional
 - Arquitectura del Modelo
 - Componentes del Modelo
- 7 Propuesta o tema central de la tesis
- 8 Resultados de la tesis**
- 9 Consideraciones finales
- 10 Referencias bibliograficas



Resultados de la tesis

Al culminar con la investigación se llegaron a resultados interesantes del punto de vista tanto teórico como computacional. ...

- **Teóricos:**



Resultados de la tesis

Al culminar con la investigación se llegaron a resultados interesantes del punto de vista tanto teórico como computacional. ...

- **Teóricos:**



Resultados de la tesis

Al culminar con la investigación se llegaron a resultados interesantes del punto de vista tanto teórico como computacional. ...

- **Teóricos:**



- **Computacionales:**



- **Computacionales:**





Modelo De Reconocimiento Automático De Señales De Tránsito Vehicular Mediante Aprendizaje Profundo De Redes Neuronales Convolucionales

- 1 Introducción
- 2 Motivación
- 3 Formulación del problema
- 4 Importancia de la investigación
- 5 Contribución de la investigación
- 6 Marco teórico
 - Aprendizaje Profundo
 - Red Convolucional
 - Arquitectura del Modelo
 - Componentes del Modelo
- 7 Propuesta o tema central de la tesis
- 8 Resultados de la tesis
- 9 **Consideraciones finales**
- 10 Referencias bibliograficas



Consideraciones finales

- **Conclusiones:**



Consideraciones finales

- **Conclusiones:**



Consideraciones finales

- **Conclusiones:**



- **Trabajos futuros:**



- **Trabajos futuros:**



- **Trabajos futuros:**



Modelo De Reconocimiento Automático De Señales De Tránsito Vehicular Mediante Aprendizaje Profundo De Redes Neuronales Convolucionales

- 1 Introducción
- 2 Motivación
- 3 Formulación del problema
- 4 Importancia de la investigación
- 5 Contribución de la investigación
- 6 Marco teórico
 - Aprendizaje Profundo
 - Red Convolucional
 - Arquitectura del Modelo
 - Componentes del Modelo
- 7 Propuesta o tema central de la tesis
- 8 Resultados de la tesis
- 9 Consideraciones finales
- 10 Referencias bibliograficas



Referencias bibliograficas

- Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. MIT Press. <http://www.deeplearningbook.org>.
- Krizhevsky, A., Sutskever, I., and Hinton, G. (2012). Imagenet classification with deep convolutional neural networks.
- OMS (2017). 10 datos sobre la seguridad vial en el mundo. <http://www.who.int/features/factfiles/roadsafety/es/>.
- Rohrer, B. (2016). How convolutional neural networks work. *Data Science and Robots Blog*.
- Sermanet, P. and LeCun, Y. (2011). Traffic sign recognition with multi-scale convolutional networks.
- SUTRAN (2014). Texto unico ordenado del reglamento nacional de transito - codigo de transito.
- Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S. E., Anguelov, D., Erhan, D., Vanhoucke, V., and Rabinovich, A. (2014). Going deeper with convolutions. *CoRR*, abs/1409.4842.
- Waze (2016). Las mejores y peores ciudades para conducir en américa latina según waze. <http://cnnespanol.cnn.com/2016/09/15/las-mejores-y-peores-ciudades>

